

基于分层卷积神经网络的皮肤镜图像分类方法

邵虹, 张鸣坤, 崔文成

(沈阳工业大学信息科学与工程学院, 辽宁 沈阳 110870)

摘要: 针对皮肤镜图像数量不充足以及各类疾病之间影像数据不平衡的问题, 提出一种融合类加权交叉熵损失函数和分层卷积神经网络的皮肤镜图像分类方法。首先对皮肤镜图像进行色彩恒常化处理, 消除环境光源噪声; 然后构建基于 ResNet 50 的分层卷积神经网络, 并在迁移学习的基础上分别构建二分类和多分类卷积神经网络模型, 根据皮肤镜图像的数量特点设置类加权交叉熵损失函数。实验结果表明, 该方法具有较好的分类效果, 分类准确率达到 85.94%, 与未改进的分类模型 ResNet 50 相比, 测试准确率提高了 5.752%。

关键词: ResNet 50; 皮肤镜图像分类; 分层卷积神经网络; 过拟合

中图分类号: TP391.4

文献标识码: A

doi: 10.11959/j.issn.2096-6652.202147

Classification method of dermoscopic image based on hierarchical convolution neural network

SHAO Hong, ZHANG Mingkun, CUI Wencheng

School of Information Science and Engineering, Shenyang University of Technology, Shenyang 110870, China

Abstract: In order to solve the problem of insufficient number of dermoscopic image and the imbalance of image data among various diseases, a classification method of dermoscopic image based on class weighted cross entropy loss function and hierarchical convolution neural network was proposed. Firstly, the dermoscopic image was processed by color constancy to eliminate the ambient light noise. Then, the hierarchical convolution neural network based on ResNet 50 was constructed, and the two classification and multi classification convolution neural network models were constructed respectively, and the class weighted cross entropy loss function was set according to the quantitative characteristics of the dermoscopic image. The experimental results show that the method achieves good classification effect, and the classification accuracy reaches 85.94%. Compared with the improved classification model ResNet 50, the test accuracy is improved by 5.752%.

Key words: ResNet 50, classification of dermoscopic image, hierarchical convolution neural network, over fitting

1 引言

皮肤病(也称皮肤色素性病变或者色素性皮肤病)是人类非常常见、高发的疾病之一, 每天有数千万人受其困扰^[1], 其诊断大多采用专业的皮肤镜设备。皮肤镜成像是一种非侵入式的(相比于组织活检)成像技术, 可以获取皮肤局部区域放大的、光照较好的图像, 同时消除皮肤表面反射, 增强皮

肤病变斑块的成像清晰度^[2]。相比于传统的视觉诊断, 这种皮肤镜的诊断方式可以大大提高准确率。

随着皮肤镜诊断方式的普及, 皮肤镜图像数据猛增。现阶段依靠紧缺的皮肤科医生通过人工筛查皮肤镜图像来诊断疾病的方式耗时长、任务繁重、较为主观。皮肤镜的使用者需要具有一定的操作和临床经验, 才能获得较好的效果。而据统计, 我国皮肤科医生缺口已经达几十万名, 并且皮肤病类型

收稿日期: 2021-02-01; 修回日期: 2021-02-24

通信作者: 张鸣坤, 1113004562@qq.com

较多,若没有专业知识的指导,患者很难做出初步自我诊断。因此针对皮肤镜图像分类算法的研究迫在眉睫。

在计算机技术发展的早期出现了很多关于皮肤镜图像分类的方法,然而这些方法往往通过人工干涉来提取图像病变区域中的纹理、色彩和轮廓等特征,然后通过提取到的特征信息对图像进行分类。

Ballerini L 等人^[3]于 2013 年通过人工提取皮肤镜图像病灶信息,对 K 最近邻算法进行了改进,并基于此实现了分类算法。

Schaefer G 等人^[4]于 2014 年利用集成学习的思想对多种常见的浅层分类算法进行了改进,实现了对皮肤镜图像的分类。

伴随着皮肤镜图像分类算法的研究,人们意识到人工提取病灶特征十分困难且不准确,越来越多的研究人员采取分割和分类相结合的方法对皮肤镜图像进行分类。

Celebi M E 等人^[5]首先采用阈值分割的方法对皮肤镜图像进行特征提取,然后基于提取到的特征利用支持向量机的方法实现了对恶性黑色素瘤的识别。

Sumithra R 等人^[6]于 2015 年对皮肤镜图像进行分割,然后采用支持向量机和 K 最近邻算法相结合的方法实现了对恶性黑色素瘤的识别。

崔文成等人^[7]于 2020 年对皮肤镜图像首先进行去除噪声处理,接着采用深度可分离卷积网络方法进行病灶分割。

普通的分割方法只能提取到皮肤镜图像色彩、纹理和轮廓等浅层次的特征信息,这会影响皮肤镜图像的分类效果。随着深度学习的发展,卷积神经网络进入人们的视野,该网络可以提取深层次的皮肤镜图像的特征信息,进而提升分类效果。

2015 年, Codella N 等人^[8]利用卷积神经网络与支持向量机实现了对皮肤镜图像中黑色素瘤的识别。

Kawahara J 等人^[9]于 2016 年对 AlexNet 进行了改进,提取了皮肤镜图像中深层次的特征信息,接着利用支持向量机的方法实现了对皮肤镜图像的二分类,准确率可达 81%。

Pomponiu V 等人^[10]于 2016 年采用迁移学习的方法通过对大量自然图像的训练构造了一个深层次的卷积神经网络,利用此网络进行了特征提取,并实现了对恶性黑色素瘤的识别。

Esteva A 等人^[11]于 2017 年采用 GoogleNet 卷积

神经网络实现了对恶性黑色素瘤的分类,准确率可达 91%。但是该方法在处理皮肤镜图像多分类的情况下准确率只有 55%。

李航等人^[12]于 2018 年采用残差神经网络对皮肤镜图像进行特征提取,接着采用支持向量机的方法实现了对皮肤镜图像恶性黑色素瘤的二分类,准确率可达 85%。

基于皮肤镜图像分类算法的发展现状,本文总结了以下不足之处。①利用卷积神经网络对皮肤镜图像进行特征提取和分类的效果取决于网络的性能,然而目前的算法往往采用单个卷积神经网络,分类准确率偏低。②皮肤镜图像的分类研究往往为二分类,尤其是对黑色素瘤的识别,对多分类问题的研究少且效果不理想。基于此,对皮肤镜图像多分类的研究还有很大空间。

2 皮肤镜图像预处理

皮肤镜图像数据往往是在不同的设备和不同的环境光源下采集得到的,这就给卷积神经网络的识别造成了很大影响,如图 1 所示的病灶周围所呈现的光亮色彩。




图1 环境光源下皮肤镜图像

为了解决这一问题,实验采用了 shades of grey 算法。该算法是对灰度世界假设 (grey-world assumption) 和白点理论 (white patch retinex) 的优化,主要步骤如下。

第一步:根据原始皮肤镜图像的 RGB 颜色空间估计出拍摄环境光源的颜色,拍摄环境光源的颜色分量为 e_c , $c \in (R, G, B)$ 可由式 (1) 估计:

$$Ke_c = \left(\frac{\int (I_c(X))^p dx}{\int dx} \right)^{\frac{1}{p}}, \quad c \in (R, G, B) \quad (1)$$

其中, I_c 表示皮肤镜图像 I 的第 c 个颜色分量; $X = (x, y)$ 表示像素位置; K 为归一化常数,起到了保证 $e_c = [e_R, e_G, e_B]^T$ 的欧氏范数和为 1 的作用; p 为 e_c 的欧氏范数的参数,最佳取值为 6。

第二步: 根据 von Kries 对角模型对皮肤镜图像 I 进行颜色转化, 该对角模型是常用的实现不同光源下图像颜色转化的方法, 如式 (2) 所示:

$$\begin{bmatrix} I'_R \\ I'_G \\ I'_B \end{bmatrix} = \begin{bmatrix} d_R & 0 & 0 \\ 0 & d_G & 0 \\ 0 & 0 & d_B \end{bmatrix} \begin{bmatrix} I_R \\ I_G \\ I_B \end{bmatrix} \quad (2)$$

其中, $[I_R, I_G, I_B]^T$ 表示原始皮肤镜图像各颜色分量的像素值, $[I'_R, I'_G, I'_B]^T$ 表示转换后在自然光源下各颜色分量的像素值, 该自然光源通常被假设成“完美白光”。系数 d_R 、 d_G 、 d_B 和拍摄环境光源颜色 e_c 之间的关系可以用式 (3) 表示:

$$d_c = \frac{1}{\sqrt{3}e_c}, \quad c \in (R, G, B) \quad (3)$$

3 基于分层卷积神经网络的分类模型

随着使用皮肤镜设备诊断皮肤病的普及, 皮肤镜图像越来越多。但是医护人员资源有限, 标注数据非常困难, 导致可用于训练的数据非常少; 再加上部分皮肤病发病率低, 造成了各类皮肤镜图像数据严重不平衡的问题, 这会给神经网络的训练造成过拟合和准确率低等问题。

针对皮肤镜图像数据的特点, 本文在 ResNet 50 卷积神经网络上, 采用迁移学习^[13]对皮肤镜图像进行分类研究。迁移学习的使用规避了数据量小这一问题。首先将皮肤镜图像分成训练集和测试集, 在算法层面, 为了提高识别准确率, 解决数据不平衡的问题, 本文设置类加权交叉熵损失函数, 给迁移学习的模型设置一个加权重, 着重学习小数据量的数据集, 并采用分层卷积神经网络进行训练。

3.1 基于 ResNet 50 的皮肤镜图像分类模型

ResNet 50 卷积神经网络又被称为残差神经网络, “50”表示网络的层数为 50, 包括 conv1、conv2_x、conv3_x、conv4_x、conv5_x 和 FC 层。conv1 为第一层, 该层为一个 $7 \times 7 \times 64$ 的卷积层, 然后是 $3+4+6+3=16$ 个瓶颈层 (bottleneck), 每个 bottleneck 为 3 层, 一共为 48 层, 最后 FC 层添加全连接层, 用于输出分类结果。

bottleneck 为残差网络单元, 其维度参数变化如图 2 所示。可以看出, 残差网络单元的设计目的是降维。首先进行 1×1 的卷积, 将维度从 256 降到 64, 接着进行 3×3 的卷积, 并在最后通过 1×1 的卷积恢复 256 维。

使用 bottleneck 后的参数数目为: $1 \times 1 \times 256 \times 64 + 3 \times 3 \times 64 \times 64 + 1 \times 1 \times 64 \times 256 = 69\,632$, 而不使用 bottleneck 的参数数目为 $3 \times 3 \times 256 \times 256 \times 2 = 1\,179\,648$ 个。




图2 残差网络单元维度参数变化

ResNet 50^[14]残差网络单元的设计解决了一般神经网络的两个重要问题: 深层神经网络退化和梯度消失。残差网络单元如式 (4) 所示:

$$H(x) = F(x) + x \quad (4)$$

假设拟合目标函数为 $H(x)$, 非线性的叠加层为 $F(x)$, 当输入为 x 时, 一般的做法是, 使 $F(x)$ 逼近 $H(x)$ 。而在残差网络单元中, x 通过抄近路 (shortcut) 链接方式一起传递, 这就使得 $F(x) + x = H(x)$, 即使 $F(x)$ 逼近 $H(x) - x$ 。

残差网络单元目标函数如图 3 所示。




图3 残差网络单元目标函数

网络退化问题指随着网络深度的增加, 性能逐渐退化, 即随着网络深度的增加, 准确率达到饱和状态, 接着准确率开始下降。但是这种现象不是由过拟合引起的, 因为训练和测试的准确率下降说明深层网络无法达到更好的训练结果, 拟合函数也不能更好地映射网络性能。而残差网络单元的设计完美地解决了这个问题, 它作用于前向传播。例如

网络映射需要将 3 映射为 3.2，没有引用残差网络单元的函数表达为 $F(3)=3.2$ ，引用残差网络单元后的函数表达为 $H(3)=3.2$ ， $H(3)=F'(3)+3$ ， $F'(3)=0.2$ ，当输出由 3.2 变为 3.3 时，映射 F 输出变化的增加为 $0.1/3.2$ ，然而映射 F' 输出变化增加为 $0.1/(0.3-0.2) \times 100\% = 100\%$ 。明显后者输出变化对权重的调整作用更大，这样就会让网络更加敏感，前向传播时浅层的特征可以在深层得到重用，完美地避开了深层神经网络退化问题。

对于梯度消失问题，残差网络单元的设计作用于反向传播，深层的梯度可以直接传回浅层，如图 4 所示。

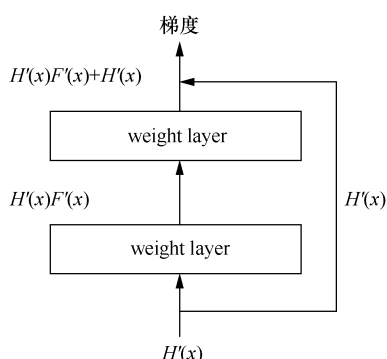


图4 反向传播残差网络单元

浅层的梯度可以分为两个部分，一部分来源于后置深层梯度的逐层累乘，另一部分沿着残差网络单元结构中的支路返回，深层的梯度可以通过残差网络单元直接传回浅层，对浅层进行更新。

3.2 类加权交叉熵损失函数

类加权的改进是基于多分类交叉熵损失函数进行的。Keras 深度学习框架中多分类交叉熵损失函数调用了 compile 函数，loss 参数设置为 categorical_crossentropy。

交叉熵损失函数如式 (5) 所示：

$$E = -\sum_k t_k \log y_k \quad (5)$$

其中， \log 表示以 e 为底数的自然对数， y_k 是神经网络的输出， t_k 是正确的标签。并且只有在标签正确的情况下 t_k 索引为 1，其余情况均为 0（用 one-hot 表示）。

类加权交叉熵损失函数改进方法如下：

$$E = -\sum_k \alpha t_k \log y_k \quad (6)$$

其中， α 为错分权重矩阵，假设第 i 类是少数类，为了加大少数类错误分类的代价，在交叉熵上给

第 i 类乘以一个大于 1 的系数，这样如果第 i 类被分错，交叉熵 E 就会增加。

本文采取按样本比例的代价敏感方式进行权重优化。根据不同类别的样本数量比例，代价敏感权重设置规则如下：样本数大的类别错分权重小，样本数小的类别错分权重大。皮肤镜图像数据集类别个数设置为 M ， M 类图像类别分别用 A_1 、 A_2 、 A_3 、 A_4 、 A_5 、 \dots 、 A_M 来表示，各类别个数分别为 N_1 、 N_2 、 N_3 、 N_4 、 N_5 、 \dots 、 N_M ，根据代价敏感权重设置规则，代价敏感权重矩阵如下：

$$C = \begin{bmatrix} 0 & N_2/N_1 & N_3/N_1 & N_4/N_1 & N_5/N_1 & \dots & N_M/N_1 \\ N_1/N_2 & 0 & N_3/N_2 & N_4/N_2 & N_5/N_2 & \dots & N_M/N_2 \\ N_1/N_3 & N_2/N_3 & 0 & N_4/N_3 & N_5/N_3 & \dots & N_M/N_3 \\ N_1/N_4 & N_2/N_4 & N_3/N_4 & 0 & N_5/N_4 & \dots & N_M/N_4 \\ N_1/N_5 & N_2/N_5 & N_3/N_5 & N_4/N_5 & 0 & \dots & N_M/N_5 \\ \dots & \dots & \dots & \dots & \dots & 0 & \dots \\ N_1/N_M & N_2/N_M & N_3/N_M & N_4/N_M & N_5/N_M & \dots & 0 \end{bmatrix} \quad (7)$$

其中， C 为 $M \times M$ 的代价敏感权重矩阵，其对角线设置为 0，其他元素以分数形式表示，得到 C 后，整体乘以 N_1 、 N_2 、 N_3 、 N_4 、 N_5 、 \dots 、 N_M 的最小公倍数，保证有效惩罚权重不小于 1。

3.3 分层卷积神经网络

为了更好地提高分类的准确率，消除过拟合问题，根据皮肤镜图像数量类别不平衡的特点，本文采用一种分层卷积神经网络模型。

实验过程中首先将第 3.2 节的 M 类中占比最多的一类或者几类表示为 M_1 ，其他类别表示为 M_2 ；接着基于 ResNet 50 构建二分类和多分类卷积神经网络模型，在构建过程中相应地采用类加权交叉熵损失函数进行优化。

设 N 为皮肤镜图像各类别数目的总和。任意一张皮肤镜图像分类的概率见表 1。

表 1 M 分类概率分布

类别	A_1	A_2	A_3	A_4	A_5	\dots	A_M
概率	$\frac{N_1}{N}$	$\frac{N_2}{N}$	$\frac{N_3}{N}$	$\frac{N_4}{N}$	$\frac{N_5}{N}$	\dots	$\frac{N_M}{N}$

根据分层卷积神经网络思想, 设皮肤镜图像 A_2 、 A_3 和 A_4 类数据样本占比大, 即:

$$N_2 + N_3 + N_4 \approx N_1 + N_5 + \dots + N_M \quad (8)$$

把 A_2 、 A_3 和 A_4 规划为第一类, 记为 M_1 ; 其余类别规划为第二类, 记为 M_2 。首先构建二分类卷积神经网络模型, 接着分别对 M_1 和 M_2 构建多分类卷积神经网络模型。

二分类卷积神经网络 M_1 分类概率如式(9)所示:

$$\text{Acc}_{M_1} = \frac{N_2 + N_3 + N_4}{N} \quad (9)$$

二分类卷积神经网络 M_2 分类概率如式(10)所示:

$$\text{Acc}_{M_2} = \frac{N_1 + N_5 + \dots + N_M}{N} \quad (10)$$

在 M_1 和 M_2 进行多分类卷积神经网络训练之前, 将 Acc_{M_1} 和 Acc_{M_2} 分别作为先验概率输入对应的多分类卷积神经网络模型。

针对 M_2 中 A_1 、 A_5 、 \dots 、 A_M 皮肤镜图像, 没有采用分层卷积神经网络的分类概率见表1, 分别为 $\frac{N_1}{N}$ 、 $\frac{N_5}{N}$ 、 \dots 、 $\frac{N_M}{N}$, 通过式(11)表示为:

$$P_i = \frac{N_i}{N}, i=1, 5, \dots, M \quad (11)$$

设 $N_1 + N_5 + \dots + N_M = N_{M_2}$, 采用分层卷积神经网络的思想, 其分类概率表示为:

$$P_2 = \text{Acc}_{M_2} \times \frac{N_i}{N_{M_2}}, i=1, 5, \dots, M \quad (12)$$

因为 $N_{M_2} < N$, 则 $\frac{N_i}{N_{M_2}} > \frac{N_i}{N}$; 在数据量充足且

数据平衡的前提下进行二分类, 很容易保证 Acc_{M_2} 分类概率接近 100%, 则有 $P_2 > P_1$ 。

分层卷积神经网络伪代码如下。

//输入: 皮肤镜图像

//构建基于 ResNet 50 的皮肤镜图像分类模型

base_model = Resnet50();

//皮肤镜图像各个类别的图像数量为 A_i , i 为不重复的集合

$$M_1 = \sum A_i, i \in m_1$$

$$M_2 = \sum A_i, i \in m_2$$

$$m_1 + m_2 = i$$

if (M1 == M2)

//构建分层卷积神经网络

//首先构建二分类卷积神经网络

base_model = Resnet50(M1, M2);

if (base_model == 'M1')

//如果二分类结果为 M_1 类, 判断 M_1 中类别个数是否为 1。

If($m_1=1$) {输出模型预测的类别信息}

Else {base_model = Resnet50(m_i)}

// i 为 M_1 类别中各个皮肤镜图像类别

if (base_model == 'M2')

//如果二分类结果为 M_2 类, 判断 M_2 中类别个数是否为 1

If($m_2=1$) {输出模型预测的类别信息}

Else {base_model = Resnet50(m_i)}

// i 为 M_2 类别中各个皮肤镜图像类别

4 实验结果

4.1 数据集

本文采取 ISIC2018 皮肤镜图像数据集, 包括基底细胞癌、光化性角化病、良性角化病、皮肤纤维瘤、黑色素瘤、黑色素细胞痣和血管病变 7 类图像。数据主要特点如下: ①除黑色素细胞痣以外的类别的训练数据集太小, 无法满足深度神经网络的需求; ②7 个类别的数据严重不平衡, 例如, 黑色素细胞痣图像大约是皮肤纤维瘤图像的 58 倍; ③公开数据集中的皮肤镜图像往往来自不同机构, 受采集环境光源颜色的影响, 皮肤镜图像往往显示为红色、紫色等异常颜色, 无法表现出病灶的真实颜色。具体见表 2。

表 2 ISIC 皮肤镜图像详细信息

皮肤镜图像	数量/张	占比
基底细胞癌	514	5.13%
光化性角化病	327	3.27%
良性角化病	1 099	10.97%
皮肤纤维瘤	115	1.15%
黑色素瘤	1 113	11.11%
黑色素细胞痣	6 705	66.95%
血管病变	142	1.42%

4.2 实验环境

本文通过 TensorFlow 实验平台, 基于 Python 的语言环境, 采用 Keras 深度学习框架实现 ResNet 50 的迁移学习, 并利用英伟达推出的 CUDA 并行计

算平台，缩短了实验的时间。具体实验环境信息见表 3。

表 3	实验环境	
	名称	参数
	处理器	I7-7700HQ
	内存	8 GB
	显卡	GTX 1050 Ti
	实验平台	TensorFlow
	实验框架	Keras
	语言	Python

4.3 实验结果

4.3.1 预处理

为了消除环境光源的影响，本文首先对皮肤镜图像进行色彩恒常化处理。实验选择 10 个训练批次 (epoch)，每个 epoch 为 600。分别对原始数据和经过色彩恒常化处理的数据进行对比实验，实验耗时见表 4，在准确率方面，两个实验的结果没有太大差别，但经过色彩恒常化处理的数据的实验时间大大缩短，这就表明，通过色彩恒常化处理去掉了皮肤镜图像的多余噪声，进而缩短了实验时间。

表 4	实验耗时	
epoch	原始数据	色彩恒常化处理过的数据
1	467 s	493 s
2	461 s	323 s
3	461 s	335 s
4	463 s	341 s
5	462 s	326 s
6	462 s	326 s
7	462 s	327 s
8	462 s	325 s
9	462 s	325 s
10	463 s	326 s

4.3.2 过拟合优化

本文首先考虑了通用的过拟合处理方法，包括：

- 以全局平均池化 (global average pooling, GAP) 代替全连接 (flatten)；
- 正则化处理；
- 添加批量归一化 (batch normalization) 层，即 BN 层；
- 添加随机失活 (dropout) 层。

考虑到正则化处理与 dropout 层混用可能造成

模型很难训练的问题，本文采取两组实验，第一组：GAP+正则化+BN；第二组：GAP+dropout+BN。第一组实验结果如图 5 所示。




图 5 GAP+正则化+BN 实验结果

第一组实验采取 10 个 epoch 训练，训练准确率稳定在 76% 左右，测试准确率稳定在 74% 左右，明显地改善了过拟合现象，但是还不够理想，准确率较低。

第二组实验结果如图 6 所示。




图 6 GAP+dropout+BN 实验结果

第二组实验采取 10 个 epoch 进行训练，可以看到无论训练准确率还是测试准确率都没有达到稳定，10 个 epoch 训练准确率达到 76%，测试准确率达到 75%。可以很明显地看出，过拟合现象基本消失，且准确率上升。接着增加到 30 个 epoch 进行训练，最终训练准确率达到 80.164%，并趋于稳定。每 10 个 epoch 的平均准确率结果见表 5。

表 5	平均准确率		
epoch	0~10	11~20	21~30
训练准确率	72.185%	78.355%	80.164%
测试准确率	71.419%	77.362%	78.938%

在实验过程中对学习率 (Lr) 和批量大小 (batchsize, 即一次训练所抓取的数据样本数量) 进行了调节, 实验结果如图 7 所示。




图7 学习率与批量大小调参优化

经过大量实验之后, 选取了最佳的 Lr 和 batchsize 的取值, Lr 为 0.005, batchsize 为 32。

4.3.3 类加权交叉熵损失函数和分层卷积神经网络的融合

通过上述实验, 10 个 epoch 的训练量无法使模型达到最优, 本节在采取 3 种权重进行针对性实验的同时, 将 epoch 改为 30, 结果如图 8 所示。




图8 类加权交叉熵损失函数实验结果

可以看到, 基于 ResNet 50 的皮肤镜图像分类模型经过类加权交叉熵损失函数改进之后, 不仅过拟合现象基本消失, 且准确率增加到 82.1%。

针对 ISIC 7 类皮肤镜图像, 根据分层卷积神经网络思想, 将黑色素细胞痣皮肤镜图像定义为第一类, 其余 6 类图像定义为第二类。首先对数据集进行二分类, 对输出的第一类结果不做处理, 对输出的第二类结果进行六分类, 实验结果如图 9 所示。




图9 类加权交叉熵损失函数+分层卷积神经网络结果

经过分层网络训练后, 训练准确率达到 85.94%, 测试准确率达到 84.69%。与表 5 中“21~30”的结果相比, 训练准确率提高了 5.776%, 测试准确率提高了 5.752%。

本文实验选取了皮肤镜图像总量的 80% 作为训练集、20% 作为测试集, 其中 TP (将正类预测为正类) 为 73.91%, TN (将正类预测为负类) 为 12.03%, FP (将负类预测为正类) 为 6.09%, FN (将负类预测为负类) 为 7.97%。详细评价指标结果见表 6。

表6 召回率、精确率和准确率

性能指标	计算方式	值
召回率	$TP/(TP+FN)$	90.27%
精确率	$TP/(TP+FP)$	92.39%
准确率	$(TP+TN)/(TP+FP+FN+TN)$	85.94%

5 结束语

本文以 ResNet 50 卷积神经网络为基础, 研究了 7 类皮肤镜图像分类方法, 针对医学图像数据集不平衡、不充分的特点, 通过在算法层面添加 GAP、dropout、正则化处理以及 BN 层避免了过拟合现象的发生, 并进行类加权交叉熵损失函数以及分层卷积神经网络的优化, 极大地提高了皮肤镜图像分类的准确率。除了算法层面, 数据方面可以收集新的数据集或者尝试使用生成对抗网络 (generative adversarial network, GAN) 进行数据增强等, 这些方法可以在未来继续研究。

参考文献:


- [1] HAY R J, JOHNS N E, WILLIAMS H C, et al. The global burden of skin disease in 2010: an analysis of the prevalence and impact of skin conditions[J]. Journal of Investigative Dermatology, 2014, 134(6):

- 1527-1534.
- [2] BINDER M, SCHWARZ M, WINKLER A, et al. Epiluminescence microscopy: a useful tool for the diagnosis of pigmented skin lesions for formally trained dermatologists[J]. Archives of Dermatology, 1995, 131(3): 286-291.
- [3] BALLERINI L, FISHER R B, ALDRIDGE B, et al. A color and texture based hierarchical K-NN approach to the classification of non-melanoma skin lesions[J]. Color Medical Image Analysis, 2013, 10(4): 63-86.
- [4] SCHAEFER G, KRAWCZYK B, CELEBI M E, et al. An ensemble classification approach for melanoma diagnosis[J]. Memetic Computing, 2014, 6(4): 233-240.
- [5] CELEBI M E, KINGRAVI H A, UDDIN B, et al. A methodological approach to the classification of dermoscopy images[J]. Computerized Medical Imaging and Graphics, 2007, 31(6): 362-373.
- [6] SUMITHRA R, SUHIL M, GURU D S. Segmentation and classification of skin lesions for disease diagnosis[J]. Procedia Computer Science, 2015, 45: 76-85.
- [7] 崔文成, 张鹏霞, 邵虹. 基于深度可分离卷积网络的皮肤镜图像病灶分割方法[J]. 智能科学与技术学报, 2020, 2(4): 385-393.
- CUI W C, ZHANG P X, SHAO H. Dermoscopic image lesion segmentation method based on deep separable convolutional network[J]. Chinese Journal of Intelligent Science and Technology, 2020, 2(4): 385-393.
- [8] CODELLA N, CAI J J, ABEDINI M, et al. Deep learning, sparse coding, and SVM for melanoma recognition in dermoscopy images[C]//Proceedings of the 6th International Workshop on Machine Learning in Medical Imaging. [S.l.:s.n.], 2015: 118-126.
- [9] KAWAHARA J, BEN TAIEB A, HAMARNEH G. Deep features to classify skin lesions[C]//Proceedings of 2016 IEEE 13th International Symposium on Biomedical Imaging. Piscataway: IEEE Press, 2016: 1397-1400.
- [10] POMPONIU V, NEJATI H, CHEUNG N M. Deepmole: deep neural networks for skin mole lesion classification[C]//Proceedings of the 23rd IEEE International Conference on Image Processing. Piscataway: IEEE Press, 2016: 2623-2627.
- [11] ESTEVA A, KUPREL B, NOVOA R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-11811.
- [12] 李航, 余镇, 倪东, 等. 基于深度残差网络的皮肤镜图像黑色素瘤的识别[J]. 中国生物医学工程学报, 2018, 37(3): 274-282.
- LI H, YU Z, NI D, et al. Identification of melanoma using dermoscopic images based on deep residual networks[J]. Chinese Journal of Biomedical Engineering, 2018, 37(3): 274-282
- [13] 田敏. 基于迁移学习的医学文献内图像多标签分类[D]. 武汉: 武汉大学, 2019.
- TIAN M. Image multi label classification within medical literature based on migration learning[D]. Wuhan: Wuhan University, 2019
- [14] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//Proceedings of the 29th IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE Press, 2016.

[作者简介]



邵虹(1974-), 女, 博士, 沈阳工业大学信息科学与工程学院教授, 主要研究方向为图像处理与模式识别、智能信息处理。



张鸣坤(1995-), 男, 沈阳工业大学信息科学与工程学院硕士生, 主要研究方向为智能信息处理。



崔文成(1973-), 男, 沈阳工业大学信息科学与工程学院副教授, 主要研究方向为智能信息处理。